



OTONOM SÜRÜŞ İÇİN LİDAR NOKTA  
BULUTLARINDAN OLUMSUZ HAVA GÜRÜLTÜSÜ  
GİDERİLMESİ

BM5511 BİLGİSAYARLI GÖRÜ DERİN ÖĞRENME  
UYGULAMALARI

Öğrenci:

Ozan PEKER-23830604002

Danışman:

Dr. CEREN GÜZEL TURHAN

# İÇİNDEKİLER

1. ÖZET .....	3
2. GİRİŞ.....	4
3. LİTERATÜR TARAMASI.....	5
4. YÖNTEM .....	6
4.1. Yapay Zeka Modeli .....	6
4.2. Veri Seti.....	7
5. DENEYSEL ÇIKTILAR .....	8
6. SONUÇ.....	9
7. KAYNAKÇA.....	10

# 1. ÖZET

Otonom araç teknolojisinin her geçen gün gelişmesiyle birlikte gündelik hayatta kullanımı da paralel olarak artmaktadır. Buna bağlı olarak gerçek dünyada kullanılan araçların yaşadığı problemler teknolojiler için bir zorluk oluşturmaktadır. Bunlardan en önemli zorluklar arasında kötü hava koşulları gelmektedir.

Kötü hava koşulları insan görüşünü etkilediği gibi aynı şekilde sensörlerinde görüşünü etkilemektedir. Bunun önüne geçmek için mevcut çalışmada kötü hava koşulların yarattığı etkilerinin iyileştirilmesine yönelik bir oto kodlayıcı çözümü önerilmiştir.

## 2. GİRİŞ

Çalışmada, otonom araçların navigasyon ve algılama yeteneklerini geliştirmek için LiDAR (Işık Algılama ve Uzaklık Belirleme) sistemlerinden elde edilen nokta bulutlarında oluşan olumsuz hava koşullarına bağlı gürültülerin azaltılmasına yöneliktir. Otonom sürüş teknolojilerinde kritik bir rol oynayan LiDAR sensörleri, yağmur, sis, kar gibi olumsuz hava koşullarında performans kaybına uğramakta ve yanlış pozitif algılamalara yol açabilmektedir. Bu problemin üstesinden gelmek amacıyla, geliştirilen algoritma, özellikle zorlu hava koşullarında LiDAR verilerinden kaynaklanan gürültüyü etkin bir şekilde filtrelemeyi hedeflemektedir.

Çalışmamız, yapay zekâ ve derin öğrenme tekniklerini kullanarak, hava koşullarından kaynaklanan gürültünün LiDAR verilerinden ayrıştırılmasına odaklanmıştır. Bu süreçte, çeşitli hava koşullarında toplanan LiDAR verileri üzerinde eğitilen bir konvolüsyonel sinir ağı (CNN) tabanlı oto kodlayıcı modeli kullanılmıştır. Model, hava gürültüsü ile gerçek çevresel nesneler arasındaki farkı tanımlayarak, gürültüyü etkin bir şekilde filtreleyebilmektedir. Modelin başarımı için açık kaynaklı A2D2 veri seti kullanılmıştır. Veri seti temiz hava koşullarında çekildiği için yağmurlu hava atmosfer modeli (LISA) kullanılarak yağmur gürültüsü eklenmiştir.

Sonuçlar, önerilen yöntemin, olumsuz hava koşullarının yol açtığı gürültüyü azaltmaya yönelik performans gösterdiğini ve LiDAR sistemlerinin doğruluk ve güvenilirliğini artırdığını göstermektedir. Bu gelişme, otonom araçların karmaşık ve değişken hava koşullarında daha güvenli ve etkili bir şekilde navigasyon yapabilmelerine olanak tanımaktadır. Ayrıca, bu çalışma, otonom sürüş sistemlerinin gelecekteki gelişimine katkıda bulunacak önemli bir adım olarak değerlendirilmektedir.

### 3. LİTERATÜR TARAMASI

Yağmur, kar ve sis gibi olumsuz hava koşulları, otonom araçlarda kullanılan LiDAR sensörlerini olumsuz etkileyebilir, güvenilirliklerini azaltabilir ve ölçümlerde istenmeyen gürültülere neden olabilir [1]. Bu sorunu ele almak için araştırmacılar, olumsuz hava koşullarında LiDAR nokta bulutlarının gürültüsünü azaltmak için çeşitli yöntemler önermişlerdir. Bu yöntemler arasında enerji tabanlı bir çerçevede aykırı değer tespiti [2], kendinden denetimli derin öğrenme yöntemleri [3] ve adaptif aykırı değer giderme filtreleri [4] bulunmaktadır. Bu yaklaşımlar, olumsuz hava koşullarında LiDAR sensörlerinin performansını iyileştirmeyi, daha güvenilir nokta bulutu elde etmeyi ve daha güvenli otonom sürüş sistemleri sağlamayı amaçlamaktadır [5]. Ayrıca, araştırmacılar farklı hava koşullarında LiDAR özelliklerinin değişkenliğini incelemiş ve yol hava koşullarını tahmin etmek için özellik seçimi yapmışlardır. Makale, olumsuz hava koşullarında LiDAR nokta bulutlarından kar gürültüsünü gidermek için 'DDIOR' adında bir dinamik filtreleme yöntemi tartışmaktadır [6]. Genel olarak, bu çalışmalar olumsuz hava koşullarında otonom sürüş için sağlam LiDAR tabanlı algılama sistemlerinin geliştirilmesine katkıda bulunmaktadır.

## 4. YÖNTEM

### 4.1. Yapay Zeka Modeli ve Ön İşlem

Bu çalışmada, yağmurun LiDAR görüntülerine etkisini modellemek için Lidar Işık Saçılımı Artırma (LISA) yöntemi kullanılmıştır. LISA, LiDAR veri setine gerçekçi yağmur modelleri ekleyerek, yağışlı hava koşullarında sensör verilerinin nasıl etkilenebileceğini simüle etmektedir. Bu süreç, temiz LiDAR veri setlerine yağmur damlalarının etkilerini ekleyerek, yağış altında sensör performansının daha iyi anlaşılmasına olanak tanımaktadır.

LISA, LiDAR verileri üzerindeki olumsuz hava koşullarının etkilerini modelleyen fizik tabanlı bir artırma yöntemidir. Küçük saçıcıların etkilerini ortalama olarak Beer-Lambert yasası kullanarak ele alır, burada yok etme katsayıları Mie teorisi ve parçacık boyutu dağılımları aracılığıyla hesaplanır. Yağmur ve kar modelleri, belirli bir yağmur oranı için temiz LiDAR nokta bulutlarını bir hibrit Monte-Carlo yöntemi kullanarak artırır. LISA, farklı damlacık boyutu modellerine veya malzemelere (örneğin toz) sahip diğer saçıcılar için kolayca genişletilebilir.

Yağmur damlalarının LiDAR verileri üzerindeki etkisini azaltmak amacıyla, bir Denoising Autoencoder (Oto Kodlayıcı) kullanılmıştır. Bu oto kodlayıcı, şu yapıyı takip etmektedir:

#### Encoder (Kodlayıcı):

- **Katman 1:** 3 giriş kanalından 16 çıkış kanalına, 3 boyutlu çekirdek, 2 adımlı (stride) ve 1 dolgulu (padding) Conv1d, ardından ReLU aktivasyon fonksiyonu.
- **Katman 2:** 16 giriş kanalından 32 çıkış kanalına, aynı çekirdek, adım ve dolgu ile Conv1d, ardından ReLU.
- **Katman 3:** 32 giriş kanalından 64 çıkış kanalına, yine aynı parametrelerle Conv1d, ardından ReLU.

#### Decoder (Kod Çözücü):

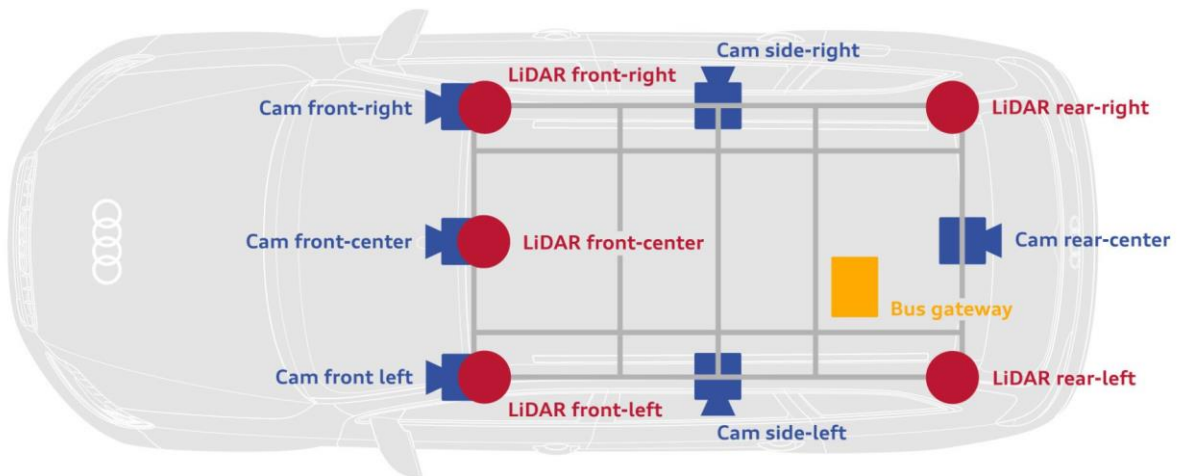
- **Katman 1:** 64 giriş kanalından 32 çıkış kanalına, 4 boyutlu çekirdek, 2 adımlı ve 1 dolgulu ConvTranspose1d, ardından ReLU aktivasyon fonksiyonu.
- **Katman 2:** 32 giriş kanalından 16 çıkış kanalına, yine aynı çekirdek, adım ve dolgu ile ConvTranspose1d, ardından ReLU.
- **Katman 3:** 16 giriş kanalından 3 çıkış kanalına, aynı parametrelerle ConvTranspose1d, ardından ReLU.

Bu yapı, LiDAR verilerinden yağmur damlalarının yol açtığı gürültüyü etkili bir şekilde azaltmak için tasarlanmıştır. Encoder, gürültülü verileri alır ve önemli özellikleri koruyarak

bu verileri sıkıştırır. Decoder ise sıkıştırılmış özellikleri kullanarak temizlenmiş verileri yeniden oluşturur.

#### 4.2. Veri Seti

Çalışma kapsamında A2D2 veri seti kullanılmıştır. Araştırma, makine öğrenmesi, mobil robotik ve otonom sürüş alanlarında, yüksek kaliteli ve etiketlenmiş verilerin bulunabilirliğiyle hız kazanmaktadır. Bu amaçla, Audi Otonom Sürüş Veri Seti (A2D2) yayımlanmıştır. Söz konusu veri seti, eş zamanlı olarak kaydedilmiş görüntüler ve 3D nokta bulutları, 3D sınırlayıcı kutular, semantik segmentasyon, örnek segmentasyon ve otomotiv veri yoluundan çıkarılmış verileri içermektedir. Sensör paketi, tam 360 derece kapsama alanı sağlayan altı kamera ve beş LiDAR ünitesinden oluşmaktadır. Kaydedilen veriler zaman senkronize edilmiş ve karşılıklı olarak kayıt altına alınmıştır. Etiketlemeler, ardışık olmayan çerçeveler için yapılmıştır: 41,277 çerçeve, semantik segmentasyonlu görüntü ve nokta bulutu etiketlerine sahiptir ve bunların 12,497'si, ön kamera görüş alanı içindeki nesneler için 3D sınırlayıcı kutu açıklamalarına da sahiptir. Ek olarak, Almanya'nın güneyindeki üç şehirde yapılan kayıtlar için 392,556 ardışık çerçeve etiketsiz sensör verisi sağlanmaktadır. Bu diziler, birkaç döngü içermektedir. GDPR mevzuatı gereği ve anonimliği korumak adına yüzler ve araç plakaları bulanıklaştırılmıştır. A2D2, ticari kullanıma, lisansın şartlarına tabi olarak CC BY-ND 4.0 lisansı altında sunulmuştur. Veri ve daha fazla bilgi <http://www.a2d2.audi> adresinde bulunabilir.



Şekil 1. Sensör Konfigürasyonu

## 5. DENEYSEL ÇIKTILAR

Veri seti üzerinde yapılmış 10 döngülük kısa bir eğitimde elde edilen eğitim hataları aşağıdaki figürde yer almaktadır. Hataların yüksek olma sebebi model içerisindeki katman sayısının az olmasından, eğitim döngü sayısının düşük olmasından ve oto kodlayıcı kullanımından kaynaklanmaktadır.

Train Epoch: 1 [998/4000 (100%)]	Loss: 755.284363
Epoch 1 Average Training loss: 802.5480	
Train Epoch: 2 [998/4000 (100%)]	Loss: 725.332520
Epoch 2 Average Training loss: 800.2192	
Train Epoch: 3 [998/4000 (100%)]	Loss: 752.355591
Epoch 3 Average Training loss: 798.2172	
Train Epoch: 4 [998/4000 (100%)]	Loss: 746.073730
Epoch 4 Average Training loss: 797.3432	
Train Epoch: 5 [998/4000 (100%)]	Loss: 838.156006
Epoch 5 Average Training loss: 796.6647	
Train Epoch: 6 [998/4000 (100%)]	Loss: 814.866089
Epoch 6 Average Training loss: 796.2530	
Train Epoch: 7 [998/4000 (100%)]	Loss: 877.406860
Epoch 7 Average Training loss: 796.1310	
Train Epoch: 8 [998/4000 (100%)]	Loss: 612.628723
Epoch 8 Average Training loss: 795.6071	
Train Epoch: 9 [998/4000 (100%)]	Loss: 685.808838
Epoch 9 Average Training loss: 795.5289	
Train Epoch: 10 [998/4000 (100%)]	Loss: 756.839050
Epoch 10 Average Training loss: 795.1454	

Şekil 2. Eğitim MSE Skor Değerleri



## 6. SONUÇ

Özel bir oto kodlayıcı modeli tanımlanarak AUDI Lidar veri seti üzerine LISA atmosfer modeli uygulanarak kötü hava koşulları eklenmiştir. Elde edilen gürültülü görüntülerdeki hasarın giderilmesi için oto kodlayıcı çözümü önerilmiştir.

Önerilen yöntem geliştirme aşamasında olup mevcut oto kodlayıcı modelin yetersiz kaldığı açık bir şekilde gözlemlenmiştir. Bu nedenle farklı konfigürasyonlar veya modeller kullanılarak geliştirmeye açıktır. Ayrıca gelecek çalışmalar görüntü verilerinin de lidar verileriyle kullanılması ile daha yüksek başarımlar elde edilmesi olasıdır.

## 7. KAYNAKÇA

1. Akhil, Kurup., Jeremy, P., Bos. (2023). Winter adverse driving dataset for autonomy in inclement winter weather. Optical Engineering, doi: 10.1117/1.OE.62.3.031207
2. (2023). Modeling the Use of LiDAR through Adverse Weather. doi: 10.5772/intechopen.109079
3. (2022). Detection of Condensed Vehicle Gas Exhaust in LiDAR Point Clouds. doi: 10.1109/itsc55140.2022.9922475
4. Alvari, Seppänen., Risto, Ojala., Kari, Tammi. (2022). 4DenoiseNet: Adverse Weather Denoising From Adjacent Point Clouds. IEEE robotics and automation letters, doi: 10.1109/LRA.2022.3227863
5. Jamil, Abdo., Luke, N., Russell., James, Mills., Taylor, D., Frailey., Genshe, Chen. (2022). Assessment of LIDAR Imaging Systems for Autonomous Vehicles in Adverse Weather and Under Dynamic Conditions. doi: 10.1115/imece2022-96259
6. Weiqi, Wang., Xiong, You., Lingyu, Chen., Jiangpeng, Tian., Fen, Tang., Lantian, Zhang. (2022). A Scalable and Accurate De-Snowing Algorithm for LiDAR Point Clouds in Winter. Remote sensing, doi: 10.3390/rs14061468